


SEMICONDUCTOR AI PROJECT

AI 기반 반도체 웨이퍼 결함 패턴 분류 모델 개발 및 시각화

반도체 양산 공정 효율화를 위한 CNN 기반
웨이퍼맵 결함 패턴 자동 분류 프로젝트

이은주

2026.07.01



목차 — 모델링 파이프라인 순서

01

프로젝트 개요 · 문제 정의

Why Automated Classification

02

데이터셋 · 결함 패턴

WM-811K Wafer Map

03

데이터 전처리 · EDA

Imbalance · Resize · Encoding

04

CNN 모델 설계

Conv2D Architecture

05

학습 · 실험 관리

Focal Loss · EarlyStopping · MLflow

06

성능 평가

Accuracy · Macro-F1 · Recall

07

결과 시각화 · 배포

Streamlit App

08

결론 · 활용 방안

Smart Manufacturing

문제 정의 및 자동 분류의 필요성

기존 방식의 한계

긴 판독 시간


웨이퍼 수량 증가에 따라 육안 검토 시간이 선형적으로 증가

주관적 판단 기준

담당 엔지니어 경험·숙련도에 따라 분류 결과가 달라질 수 있음

조기 감지 지연

이상 패턴 인지가 늦어지면 수율 손실·품질 이슈가 확대



CNN 기반 웨이퍼맵 자동 분류

- 공간 패턴의 일관된 기계적 학습 및 분류
- 엔지니어 판독 의존도 감소 · 업무 집중도 향상
- 공정 이상 조기 신호 포착으로 수율 보호

8가지 결함 패턴 자동 인식

웨이퍼맵 결함 패턴 개요

WM-811K — 실제 FAB 웨이퍼맵 · 8가지 주요 결함 클래스 (공간 패턴 = 공정 이상 신호)



Center

중앙 공정 조건 / 온도 균일도



Donut

반경 방향 공정 균일도




Edge-Ring

엣지 공정 조건 / 핸들링




Edge-Loc

국부 장비 접촉 / 포지셔닝



Scratch

물리적 스크래치 / 이송 접촉



Loc

파티클 / 국부 공정 편차



Near-full

전역 공정 실패 / 레시피 오류




Random

확률적 노이즈성 불량

데이터 전처리 및 EDA

클래스별 샘플 웨이퍼맵 시각화




데이터 전처리 및 EDA

핵심 이슈 — 클래스 불균형

정상(none) 약 86%

결함 8종 합계 약 14%

→ 정확도(accuracy)만으로는 성능 왜곡




대응 전략

라벨 미검토(unlabeled) 행 제외 — '정상'과 구분

CAP_NONE — 정상 클래스 20000으로 상한, 결함은 전부 유지

Focal Loss로 불균형 보정 (학습 단계) — GAMMA 값 2.0 → 3.0



데이터 전처리 및 EDA

```
X = []
for wm in df['waferMap']:
    arr = np.asarray(wm, dtype='float32')
    arr = cv2.resize(arr, (IMG_SIZE, IMG_SIZE), interpolation=cv2.INTER_NEAREST)
    X.append(arr.astype('uint8'))
X = np.array(X)[..., np.newaxis]
y = df['label'].values
return X, y
```

```
from tensorflow.keras.utils import to_categorical

le = LabelEncoder()
y_int = le.fit_transform(y_str)
num_classes = len(le.classes_)
print('클래스:', list(le.classes_))

y = to_categorical(y_int, num_classes)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y_int, random_state=42
)
print('학습:', X_train.shape, ' / 테스트:', X_test.shape)
```

전처리 파이프라인

1

웨이퍼맵 리사이즈

가변 크기 → 128×128 (최근접 보간, 0/1/2 값 보존)

2

정규화

Rescaling(1/2) — 0/1/2 값을 0~1 범위로

3

라벨 인코딩

LabelEncoder → one-hot (Focal Loss용)

4

학습/테스트 분리

train_test_split · stratify로 클래스 비율 유지

CNN 모델 설계



Focal Loss ($\gamma = 3.0$)

맞이기 쉬운 다수 클래스(none)의 손실을 깎아
드문 결함 패턴 학습에 집중 → 불균형 보정의 핵심

Optimizer	Adam
Activation	ReLU / Softmax
과적합 방지	Data Augmentation · Dropout 0.3
해상도	128x128 (Loc/Edge-Loc 구분 강화, Edge-Loc/Edge-Ring 구분 강화)

학습 및 실험 관리

학습 전략

1

Focal Loss

다수 클래스 억제, 드문 결함에 집중

2

EarlyStopping

val_loss 5회 미개선 시 중단, 최적 가중치 복원

3

Class 유지

결함 8종 전부 사용 (데이터 안 버림)

4

Batch / Epoch

32 / 최대 30 (상한, 자동 조기 종료)

5

MLflow 실험 추적


설정·기법을 바꿀 때마다 자동 기록 → 실험 비교

Parameters img_size · focal_gamma · cap_none · batch

Metrics test_accuracy · macro_f1 / precision · 클래스별 recall

Artifacts 혼동행렬 이미지 · 분류 리포트

Model 학습 모델 버전 자동 저장



실험 비교 — 클래스 불균형 튜닝





CAP_NONE 값에 따른 Macro-F1 변화 (MLflow 4개 run 비교)

핵심 인사이트

- none(정상)을 줄일수록 결함 recall은 계속 상승
- 그러나 10,000 미만에선 정상 오판(false alarm)이 늘어 Macro-F1 하락
- recall 단일 지표가 아닌 Macro-F1 기준으로 최적점 탐색
- cap=10,000을 최종 채택 (변곡점)

불균형을 정량적으로 튜닝 → 올바른 지표로 판단

실험 비교 — Confusion Matrix 전/후



성능 평가 — Best Run (cap_none=10,000)

Test Accuracy

92.4%

(참고 지표)

Macro-F1

0.90

핵심 지표 · 클래스 공평

Macro-Precision

0.90

오판(false alarm) 균형

테스트 정확도 (accuracy): 0.9237
Macro-F1 (클래스 공평 평균): 0.8986


	precision	recall	f1-score	support
Center	0.95	0.97	0.96	859
Donut	0.80	0.87	0.83	111
Edge-Loc	0.86	0.87	0.87	1038
Edge-Ring	0.95	0.99	0.97	1936
Loc	0.85	0.79	0.82	719
Near-full	1.00	0.93	0.97	30
Random	0.97	0.88	0.92	173
Scratch	0.74	0.86	0.80	238
none	0.98	0.92	0.95	2000
accuracy			0.92	7104
macro avg	0.90	0.90	0.90	7104
weighted avg	0.93	0.92	0.92	7104

결과 해석


- 정확도(92.4%)는 참고용 — 정상 비중 보정 후에도 **Macro-F1 0.90** 달성
- Scratch·Edge-Loc의 정상(none) 누락 대폭 감소 — 불량 놓침 최소화
 - Recall·Precision 균형(0.90/0.90)으로 false alarm도 억제
 - 한계: Loc(recall 0.79)가 최저 — 국부 불량 패턴 다양성 때문, 추가 데이터·고해상도로 개선 여지

성능 평가 — Training vs Validation


Training and Validation Accuracy



Training and Validation Loss



Grad-CAM — 결함 판단 근거 시각화 (XAI)



따뜻한 색(노랑, 빨강)이 진할수록 예측 기여가 큰 영역 — Scratch의 굵은 선·Random의 분산 영역에 정확히 집중

결과 시각화 및 배포 — Streamlit

반도체 웨이퍼 결함 패턴 분류 (CNN)

WM-811K 학습 모델 기반 - 웨이퍼 결함 패턴을 진단하고 추정 공정 원인을 제시합니다

🔥 프로젝트 개요 🖼️ 웨이퍼 결함 예측 📊 클래스 정보 📘 모델 정보


웨이퍼 결함 패턴 예측

.npy 웨이퍼 (2D 배열, 0/1/2 값)를 업로드하거나, 샘플 패턴을 생성해 테스트하세요.

웨이퍼 업로드 (.npy)

📁 Upload 200MB per file • NPY

Pred: Scratch (89.9%)



또는 샘플 패턴 생성

Scratch

예측 결함 패턴

Scratch

↑ 89.9%

나타나는 형태: 가늘고 길게 선(줄) 형태로 이어져 나타남

추정 공정 원인: 핸들링-이송 중 로트 압/캐리어 기계적 긁힘, CMP-세정 중 스크래치 의심



결론 및 제조 현장 활용 방안

1 Smart Manufacturing 구현

공정 데이터(웨이퍼맵)에 AI/ML 적용한 양산 효율화 사례

2 IT × OT 융합

공정·장비 도메인 지식 + 딥러닝 결합, 패턴→공정원인 해석

3 Work With AI

육안 검사 자동화로 반복 업무 제거·판단 지원

4 Digital Twin 확장

FDC·MES 연계 실시간 이상탐지, 가상 검증으로 발전

THANK YOU

감사합니다

AI 기반 반도체 웨이퍼 결함 패턴 분류 · Smart Manufacturing

CNN · Conv2D · MaxPooling · Dropout · Dense · Focal Loss

2026 · Smart Manufacturing · MLflow

